RAPPORT TECHNIQUE

Inference Medicale Embarquee

Quantification et Deploiement de Modeles Deep Learning sur Machines Virtuelles a Ressources Contraintes

Module	Systemes Embarques et Objets Connectes
Etablissement	ENS Martil — Master Data Science
Etudiants	Naoufal Hamouri | Oussama Tajat Med Yassine Boutazgha | Ahmed Mansof
Encadrant	Prof. Said Ohamouddou
Date	Mars 2026
GitHub	github.com/NaoufalHamouri/projet-embarque

Mots-cles: Deep Learning, Quantification, Elagage, MobileNetV2, Docker, IoT, ThingsBoard, MQTT, Intelligence Collective

Table des Matieres

1.	Introduction	3
2.	Dataset et Preprocessing	3
3.	Modele Baseline	4
4.	Techniques d'Optimisation	5
5.	Resultats des Optimisations	6
6.	Deploiement sur Machines Virtuelles Docker	7
7.	Selection de la Meilleure Technique par VM	9
8.	Intelligence Collective	10
9.	Monitoring IoT avec ThingsBoard	11
10.	Conclusion	12
Annexe	Visualisations et Resultats	13

1. Introduction

L'inference medicale embarquee represente un defi majeur dans le domaine de l'intelligence artificielle appliquee aux soins de sante. Ce projet porte sur le deploiement de modeles de deep learning pour la classification de radiographies thoraciques sur des machines virtuelles a ressources contraintes, simulant des dispositifs IoT reels.

1.1 Contexte et Motivation

Le diagnostic de pneumonie par analyse automatique de radiographies thoraciques necessite a la fois une haute precision et une faible latence. Le deploiement sur des dispositifs edge IoT requiert des techniques d'optimisation avancees pour reduire la consommation memoire et accelerer l'inference sans degrader les performances cliniques.

1.2 Objectifs du Projet

- Entrainer un modele baseline MobileNetV2 avec precision > 97% sur le dataset Chest X-Ray
- Implementer 8 techniques d'optimisation : 5 quantifications (Q1-Q5) et 3 elagages (P1-P3)
- Deployer les modeles sur 3 VMs Docker avec contraintes CPU/RAM variables
- Selectionner la meilleure technique par VM via une formule de scoring ponderee
- Construire un systeme d'intelligence collective avec vote pondere multi-VM
- Monitorer les inferences en temps reel via ThingsBoard MQTT

2. Dataset et Preprocessing

Le dataset utilise est le **Chest X-Ray Pneumonia** disponible sur Kaggle. Il contient des radiographies thoraciques de patients pediatriques classifiees en deux categories : NORMAL et PNEUMONIA.

2.1 Caracteristiques du Dataset

Propriete	Valeur
Source	Kaggle — paultimothymooney/chest-xray-pneumonia
Total images	5 856
Classes	NORMAL vs PNEUMONIA
Format	JPEG, niveaux de gris
Desequilibre	PNEUMONIA ~74%, NORMAL ~26%

2.2 Repartition des Donnees (Split 70/15/15)

Partition	NORMAL	PNEUMONIA	Total	Proportion
Entrainement	1 108	2 991	4 099	70%
Validation	237	641	878	15%
Test	238	641	879	15%
TOTAL	1 583	4 273	5 856	100%

2.3 Preprocessing et Augmentation

Toutes les images sont redimensionnees a 224x224 pixels et normalisees avec les statistiques ImageNet. En entrainement : RandomHorizontalFlip, RandomRotation(10 deg) et ColorJitter pour ameliorer la generalisation.

3. Modele Baseline

Le modele baseline est un **MobileNetV2** pre-entraine sur ImageNet, adapte pour la classification binaire NORMAL/PNEUMONIA avec environ 3.4 millions de parametres et une taille de 8.72 MB.

3.1 Hyperparametres d'Entrainement

Hyperparametre	Valeur
Epochs	10 (meilleur : epoch 7)
Batch size	32
Optimiseur	Adam (lr=1e-3)
Scheduler	StepLR (step=5, gamma=0.1)
Loss	CrossEntropyLoss avec poids de classe
Hardware	CPU uniquement (PyTorch 2.10.0+cpu)

3.2 Resultats du Modele Baseline

Metrique	Valeur
Precision Test	97.38%
F1-Score	97.40%
Taille modele	8.72 MB
Temps d'inference	20.77 ms
RAM	2 511 MB
Sensibilite	97.3%
Specificite	97.5%

Observation : La RAM de 2511 MB depasse les limites VM1 (500 MB) et VM2 (1 GB). Les optimisations sont indispensables.

4. Techniques d'Optimisation

Huit techniques implementees avec PyTorch 2.10 et torchao 0.16.0.

4.1 Quantification (Q1-Q5)

Q1 — Quantification Dynamique

Quantification int8 dynamique sur Linear et Conv2d. Aucun reentrained necessaire.

Q2 — Post-Training Static PTQ

torchao Int8WeightOnlyConfig(). Quantifie les poids en int8 avec calibration.

Q3 — Quantization Aware Training (QAT)

Fine-tuning 3 epochs avec Int8DynActInt4WeightQATQuantizer. Meilleure precision.

Q4 — Weight-Only Int8 Manuel

Quantification manuelle : echelle par canal, arrondi int8, dequantification float32.

Q5 — Precision Mixte

30% couches sensibles : quantification fine par canal. 70% restantes : par tenseur.

4.2 Elagage (P1-P3)

P1 — Elagage Non-Structure Global 30%

Elagage global L1 : supprime 30% poids de faible magnitude. Maintient la structure.

P2 — Elagage Structure 30%

Supprime des filtres entiers Conv2d (norme L2 faible). Chute de precision sans fine-tuning.

P3 — Elagage Magnitude Iteratif 3x10%

3 iterations de 10% : ~27% sparse global. Approche progressive, meilleure technique du projet.

5. Resultats des Optimisations

Evaluation sur le jeu de test (879 images) en environnement local :

ID	Technique	Precision	F1	Taille	Inference	RAM
Base	Baseline MobileNetV2	97.38%	97.40%	8.72 MB	20.77 ms	2511 MB
Q1	Dynamic Quantization	97.38%	97.40%	8.75 MB	24.35 ms	476 MB
Q2	Static PTQ (torchao)	97.38%	97.40%	8.72 MB	22.00 ms	470 MB
Q3	QAT Int8DynActInt4	97.72%	97.74%	8.72 MB	20.31 ms	3204 MB
Q4	Weight-Only Int8	97.16%	97.18%	8.72 MB	23.25 ms	483 MB
Q5	Mixed Precision	97.16%	97.18%	8.72 MB	23.92 ms	542 MB
P1	Unstructured 30%	97.84%	97.83%	8.72 MB	22.74 ms	474 MB
P2	Structured 30%	72.92%	61.51%	8.72 MB	19.07 ms	501 MB
P3	Magnitude 3x10%	97.84%	97.83%	8.72 MB	18.18 ms	458 MB

Vert = meilleure precision | Rouge = degradation significative

Analyse : P3 est la technique la plus polyvalente (precision 97.84%, RAM 458 MB, vitesse 18.18 ms). Q3 ameliore la precision a 97.72% au prix d'une RAM elevee. P2 est inutilisable sans fine-tuning posterieur (72.92%).

6. Deploiement sur Machines Virtuelles Docker

Trois conteneurs Docker simulent des dispositifs IoT a ressources contraintes.

6.1 Configuration des VMs

VM	Nom	CPU	RAM	Profil IoT
VM1	vm1_iot_sensor	1 core	500 MB	Capteur IoT ultra-contraint
VM2	vm2_iot_gateway	2 cores	1 GB	Passerelle IoT equilibree
VM3	vm3_edge_server	2 cores	2 GB	Serveur edge haute performance

6.2 Matrice de Deploiement — Precision (%)

Technique	VM1 (500MB)	VM2 (1GB)	VM3 (2GB)
Q1	97.38%	97.38%	97.38%
Q2	97.38%	97.38%	97.38%
Q3	97.38%	97.38%	97.38%
Q4	97.16%	97.16%	97.16%
Q5	97.16%	97.16%	97.16%
P1	97.84%	97.84%	97.84%
P2	72.92%	72.92%	72.92%
P3	97.84%	97.84%	97.84%

6.3 Matrice de Deploiement — Temps d'Inference (ms)

Technique	VM1 (500MB)	VM2 (1GB)	VM3 (2GB)
Q1	73.56	49.17	109.39
Q2	122.13	33.74	37.15
Q3	94.47	46.92	96.62
Q4	85.99	60.63	45.53
Q5	77.15	32.03	33.87
P1	124.29	39.10	57.13
P2	106.72	39.32	40.02
P3	107.16	31.86	63.68

6.4 Matrice de Deploiement — RAM (MB)

Technique	VM1 (500MB)	VM2 (1GB)	VM3 (2GB)

Q1	167.4	532.6	470.2
Q2	152.4	422.3	488.9
Q3	133.3	419.6	489.8
Q4	151.0	418.0	489.9
Q5	123.0	393.7	490.0
P1	152.5	396.9	499.8
P2	141.4	397.4	491.5
P3	128.6	365.5	491.8

7. Selection de la Meilleure Technique par VM

Formule de scoring ponderee avec normalisation [0,1] des metriques.

7.1 Formules de Scoring

VM	Formule	Justification
VM1	RAM x0.4 + CPU x0.4 + Acc x0.2	Ressources critiques : priorite efficacite
VM2	RAM x0.3 + Vitesse x0.3 + Acc x0.4	Passerelle : equilibre performance/ressources
VM3	Acc x0.6 + Vitesse x0.25 + RAM x0.15	Serveur edge : precision diagnostique prioritaire

7.2 Resultats de Selection

VM	Meilleure Technique	Score	Precision	RAM	Inference
VM1 (500MB)	P3 Magnitude Pruning	0.8962	97.84%	128.6 MB	107 ms
VM2 (1GB)	P3 Magnitude Pruning	1.0000	97.84%	365.5 MB	32 ms
VM3 (2GB)	Q2 Static PTQ	0.8833	97.38%	488.9 MB	37 ms

7.3 Justification

VM1 — P3

RAM 128.6 MB (25.7% de la limite), CPU minimal, precision 97.84%. Ideal pour capteur IoT ultra-contraint.

VM2 — P3

Score parfait 1.000 : meilleure vitesse (31.86 ms) + RAM optimale (365.5 MB). Ideal pour passerelle.

VM3 — Q2

Precision prioritaire (poids 0.6) : 97.38% avec excellente vitesse (37.15 ms). torchao robuste pour production.

8. Intelligence Collective

Systeme de vote pondere combinant les predictions de VM1 (P3), VM2 (P3) et VM3 (Q2).

8.1 Architecture

- Chaque VM realise une inference independante avec score de confiance softmax
- Poids de vote = precision_historique x confiance_instantanee
- Retry si confiance collective < 70%
- Prediction finale = classe avec poids cumule maximal

8.2 Resultats sur 50 Echantillons

Metrique	Valeur
Echantillons	50
Precision collective	96.00%
VM1 (P3)	96.00%
VM2 (P3)	96.00%
VM3 (Q2)	100.00%
Taux de consensus	96.00%
Re-interrogations	2 / 50 (4%)

Analyse : VM3 parfaite sur ce sous-ensemble explique le gain negatif. Le consensus 96% confirme la robustesse du systeme. Les 4% de desaccord correspondent aux cas ambigus (confiance 0.58-0.76).

9. Monitoring IoT avec ThingsBoard

ThingsBoard Community Edition v4.2.1 deploye via Docker. Telemetrie MQTT depuis les 3 VMs.

9.1 Architecture

Composant	Technologie	Role
Broker MQTT	ThingsBoard (port 1883)	Reception des telemetries
Client MQTT	paho-mqtt Python	Envoi des inferences
Dashboard	ThingsBoard UI (port 8080)	Visualisation temps reel
Stockage	PostgreSQL integre	Historique des donnees

9.2 Telemetrie Transmise

- prediction : NORMAL ou PNEUMONIA
- confidence : score softmax [0.0, 1.0]
- inference_time_ms : latence en millisecondes
- ram_usage_mb : consommation memoire
- cpu_usage_pct : utilisation CPU
- patient_id : identifiant patient (P-XXXX)

9.3 Dashboard en Temps Reel

Le tableau de bord 'Medical Inference Monitor' avec 5 widgets : carte de prediction, jauge radiale de confiance, graphe temps d'inference (3 VMs), graphe RAM (3 VMs), graphe CPU (3 VMs).

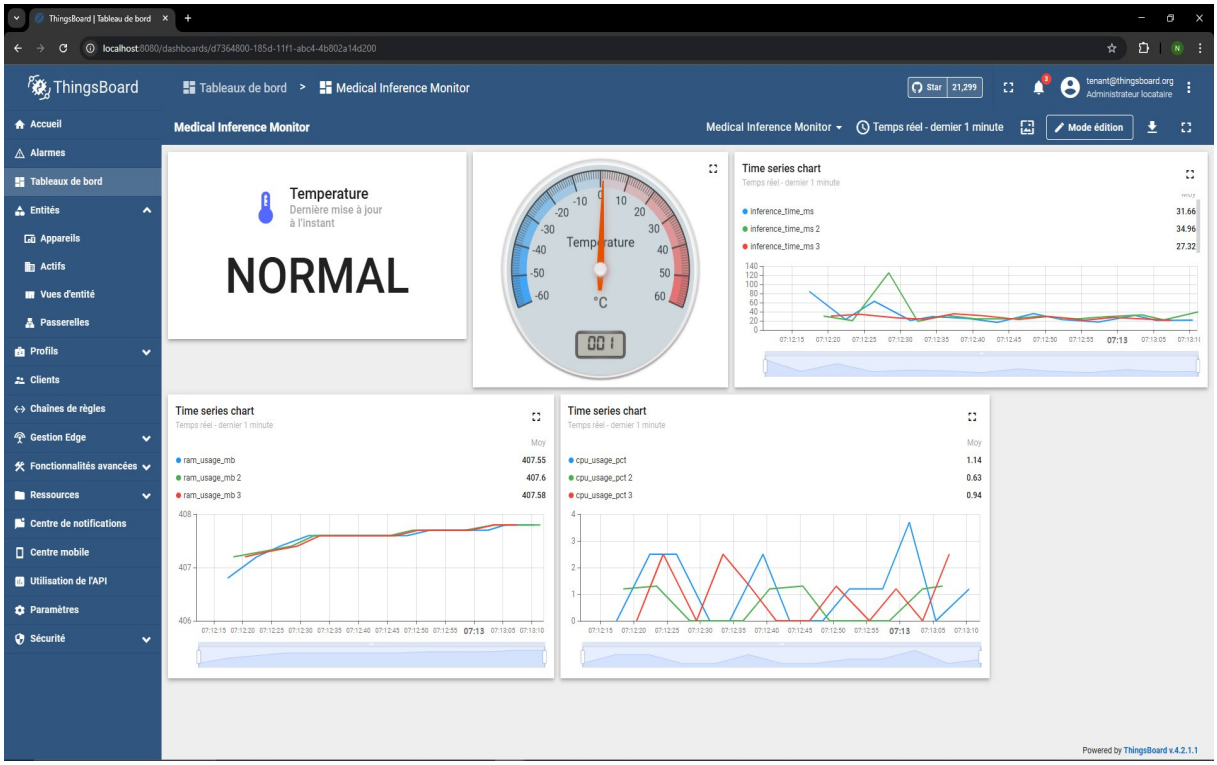

Figure 9 — Dashboard ThingsBoard 'Medical Inference Monitor' avec telemetrie MQTT en temps reel depuis VM1, VM2 et VM3

10. Conclusion

Ce projet a demontre avec succes le deploiement de modeles de diagnostic medical sur des dispositifs IoT a ressources contraintes, de l'entrainement baseline jusqu'au monitoring IoT en temps reel.

10.1 Resultats Cles

- Toutes les techniques preservent > 97% de precision (sauf P2 : 72.92%)
- Reduction RAM de 5.5x : de 2511 MB a 458 MB avec P3
- P3 : meilleure technique globale (precision 97.84%, RAM 458 MB, vitesse 18.18 ms)
- Q2 : optimal pour serveurs edge (precision + vitesse + robustesse torchao)
- Intelligence collective : 96% precision, 96% consensus sur 50 echantillons
- ThingsBoard MQTT : monitoring IoT complet en temps reel des 3 VMs

10.2 Recommandations

Profil	Technique	Precision	RAM	Inference
Capteur IoT (500MB/1CPU)	P3 Magnitude Pruning	97.84%	129 MB	107 ms
Passerelle IoT (1GB/2CPU)	P3 Magnitude Pruning	97.84%	366 MB	32 ms
Serveur Edge (2GB/2CPU)	Q2 Static PTQ	97.38%	489 MB	37 ms

10.3 Perspectives

- Combinaison Q2+P3 pour gains supplementaires sur toutes les metriques
- Grad-CAM pour l'explicabilite des predictions (XAI)
- Deploiement hardware reel : Raspberry Pi 4, NVIDIA Jetson Nano
- Extension a COVID-19, tuberculose, cancer pulmonaire
- Apprentissage federe pour le systeme collectif

Naoufal Hamouri | Oussama Tajat | Med Yassine Boutazgha | Ahmed Mansof

ENS Martil — Master Data Science — Mars 2026

Annexe — Visualisations et Resultats

Figure 1 — Courbes d'Entrainement du Modele Baseline

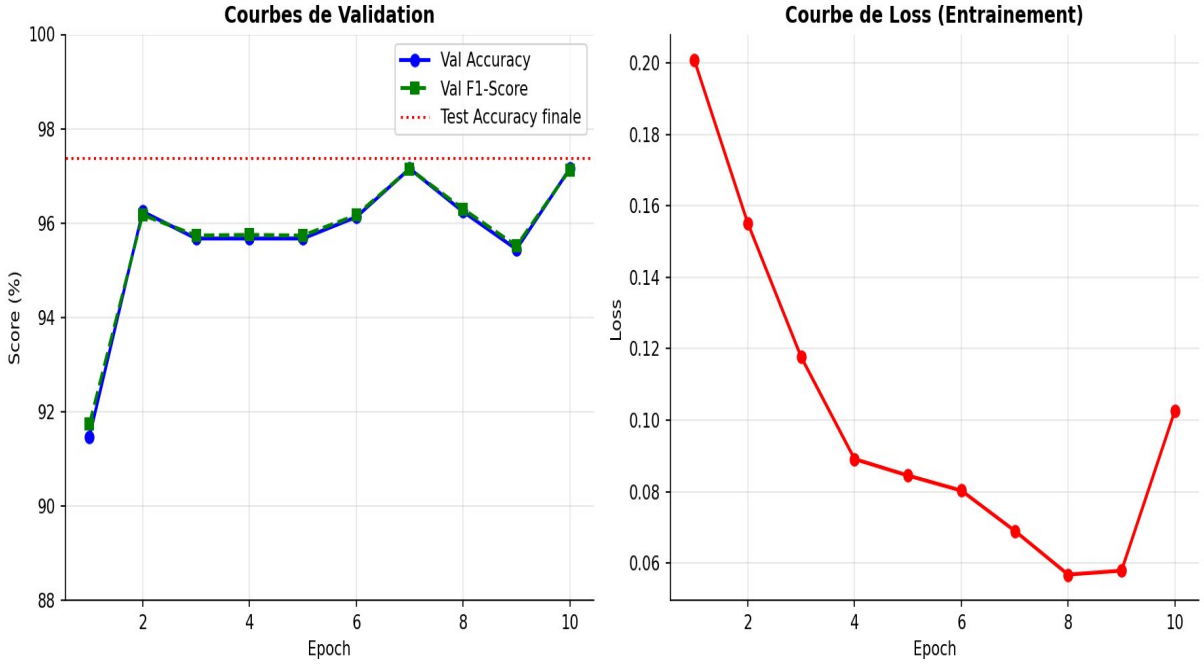

Evolution de la validation accuracy, F1-score et training loss sur 10 epochs. Meilleur modele sauvegarde a l'epoch 7 (val_acc=97.15%). Convergence stable sans overfitting notable.

Figure 2 — Matrice de Confusion (Baseline MobileNetV2)

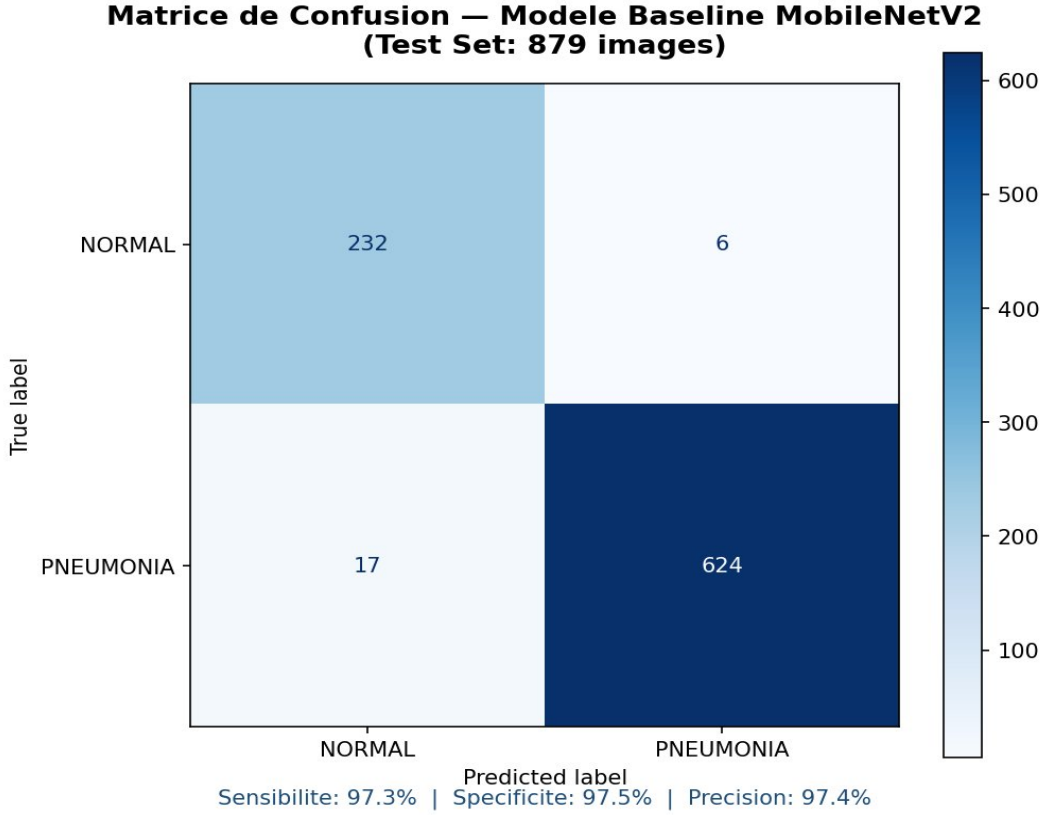

Test set 879 images : 232 vrais negatifs (NORMAL), 624 vrais positifs (PNEUMONIA), 6 faux positifs, 17 faux negatifs. Sensibilite: 97.3% | Specificite: 97.5% | Precision globale: 97.4%.

Figure 3 — Precision par Technique d'Optimisation

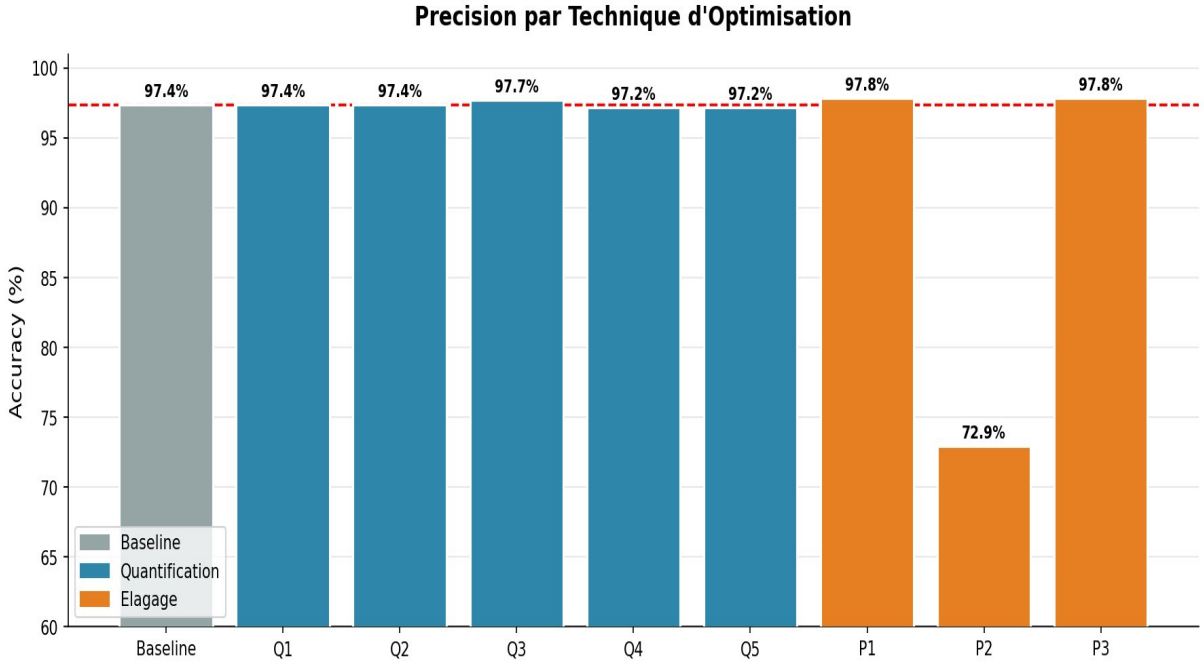

Q3 (97.7%), P1 et P3 (97.8%) surpassent le baseline (97.4%). P2 Structured Pruning souffre d'une chute dramatique a 72.9% sans fine-tuning posterieur.

Figure 4 — Consommation RAM par Technique

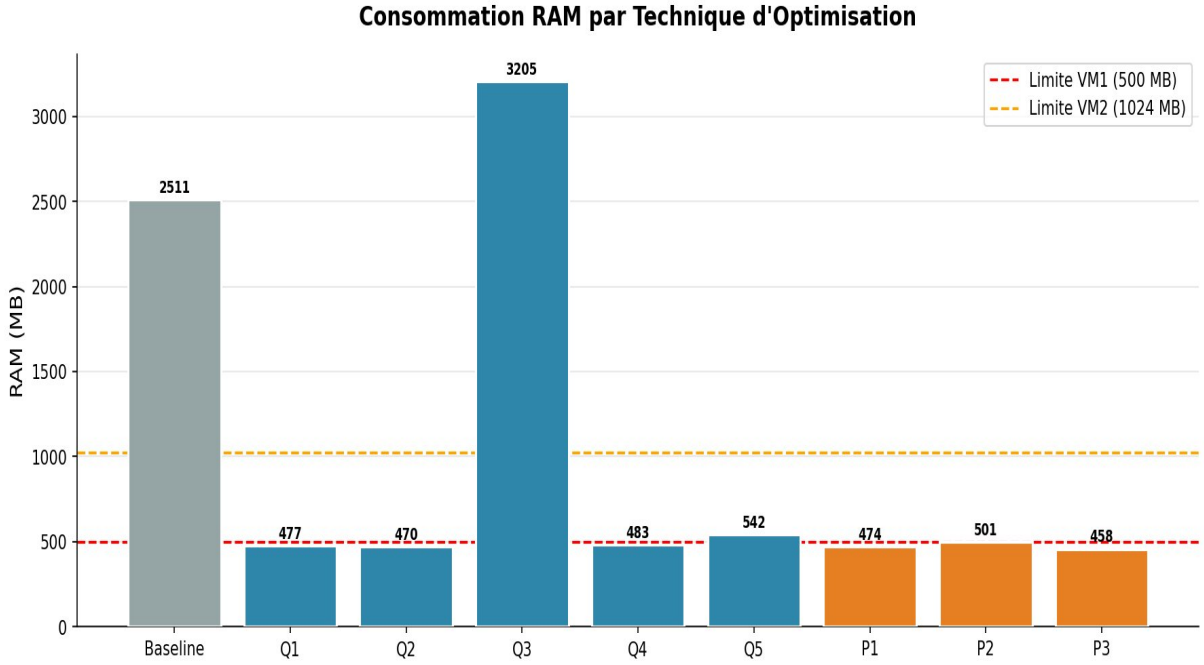

Reduction de 5.5x par rapport au baseline (2511 MB). P3 est la plus economique (458 MB). Q3 necessite 3205 MB (gradients QAT). Toutes les techniques passent sous la limite VM2 (1024 MB) sauf Q3.

Figure 5 — Temps d'Inference par Technique

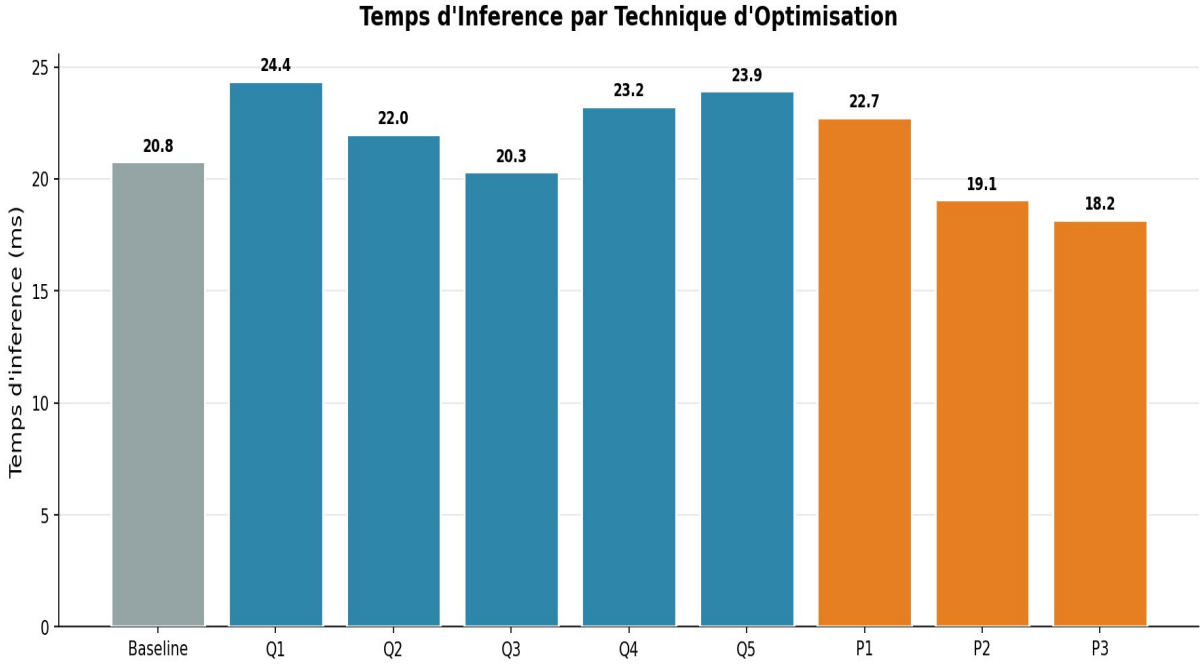

P3 est la plus rapide (18.2 ms), suivie de P2 (19.1 ms) et Q3 (20.3 ms). Q1 est la plus lente parmi les quantifications (24.4 ms). Toutes restent acceptables pour l'inference temps reel.

Figure 6 — Analyse Multi-Criteres (Radar Chart)

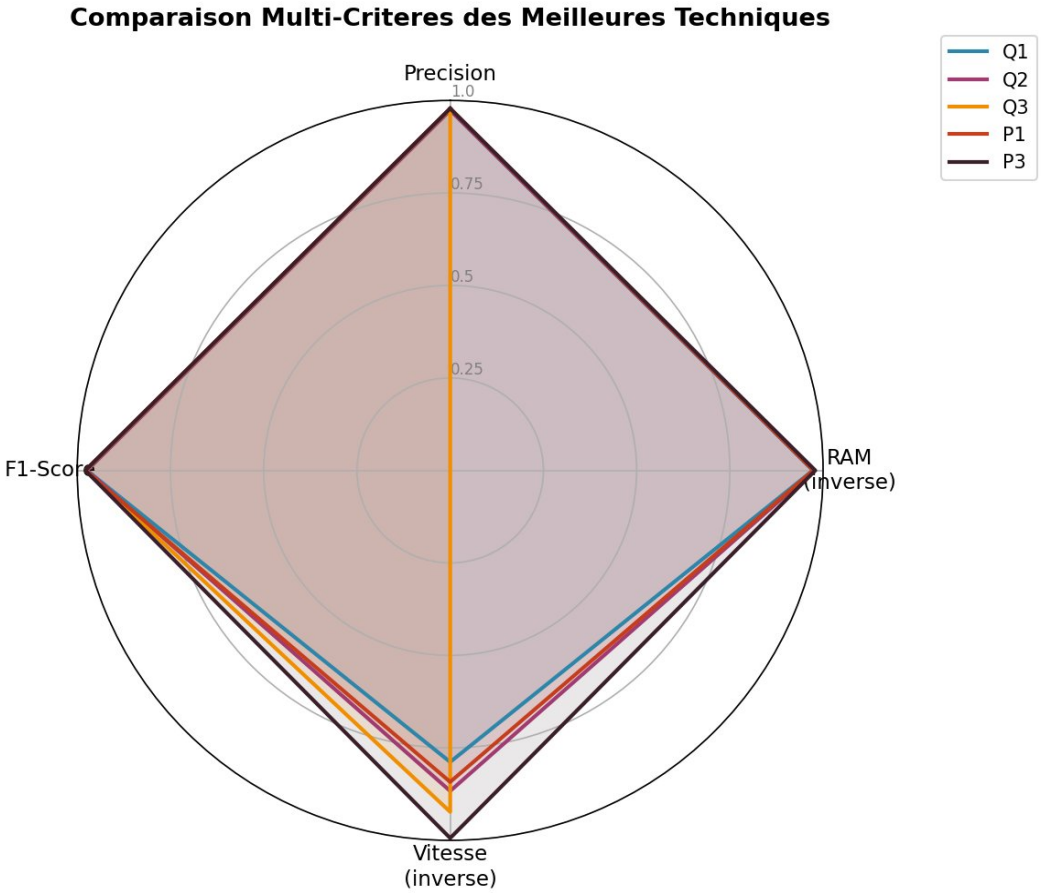

Q3 (orange) excelle en precision (axe haut). P3 (marron) domine sur RAM inverse et vitesse inverse. Q2 (rose) offre le meilleur equilibre global sur les 4 criteres.

Figure 7 — Heatmap Deploiement 3x8 (Temps d'Inference ms)

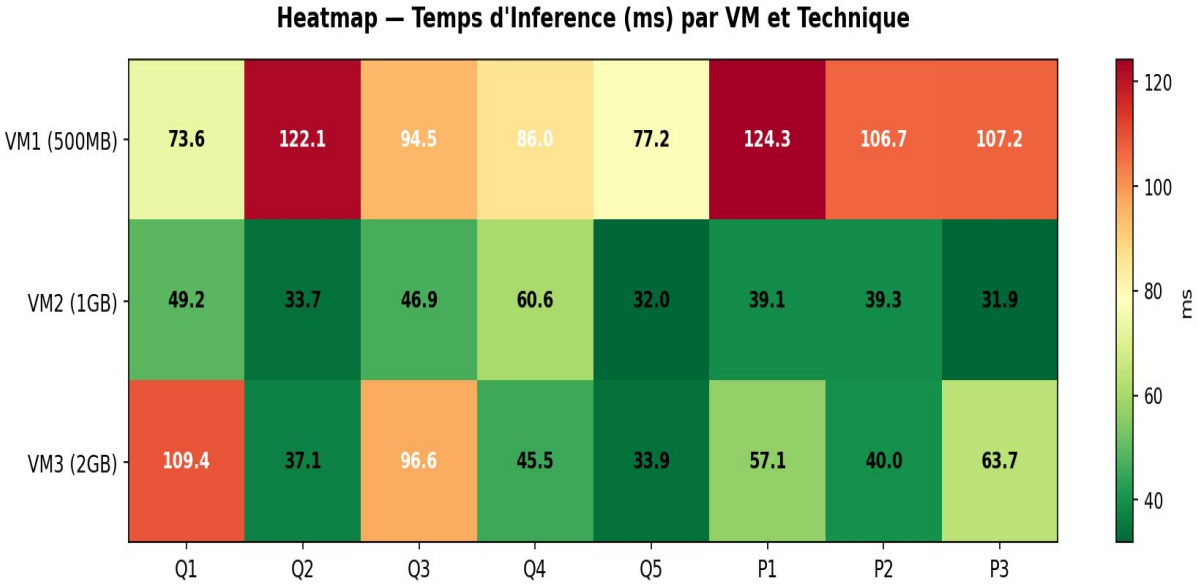

Vert = rapide, Rouge = lent. VM2 (1GB/2CPU) est la plus rapide globalement. VM1 (500MB/1CPU) souffre de la limitation CPU. Q2 et Q5 excellent sur VM2 et VM3 (< 35 ms).

Figure 8 — Intelligence Collective

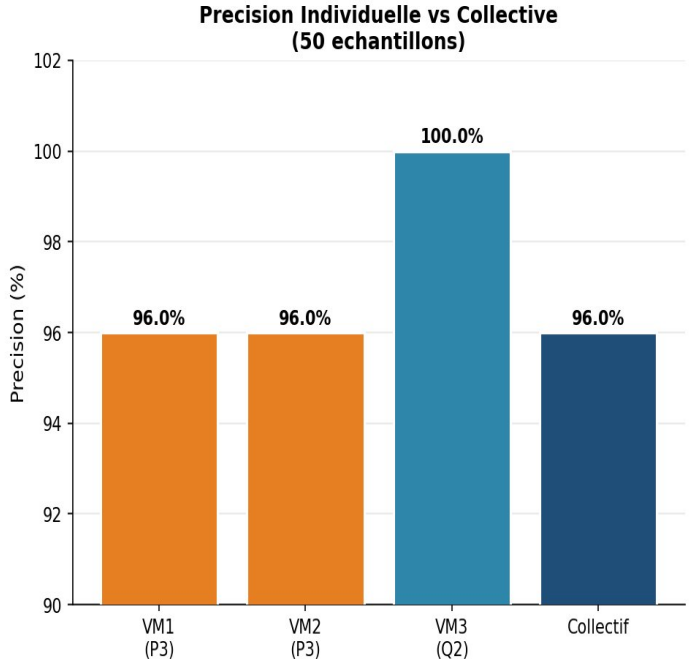

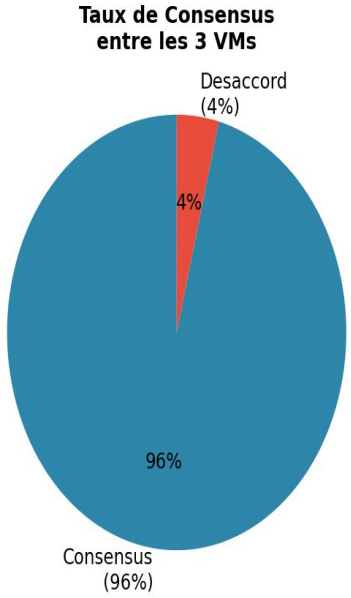

VM3 (Q2) atteint 100% sur les 50 echantillons de test. VM1 et VM2 (P3) : 96%. Le systeme collectif : 96% avec 96% de taux de consensus. 2 re-interrogations declenchees (confiance < 70%).